

학사학위논문

Performance Comparison of Pre-Trained CNN
Models

in CT Image Prediction

- 의료 CT 영상 분류를 위한 사전학습 모델 평가 연구 -

지도교수 박기주

경희대학교

생체의공학과

이 레 2021110110

2025년 12월

Performance Comparison of Pre-Trained CNN
Models
in CT Image Prediction

- 의료 CT 영상 분류를 위한 사전학습 모델 평가 연구 -

지도교수 박기주

이 논문을 학사 학위논문으로 제출함

└

경희대학교

생체의공학과

이 레

2025년 12월

이 레의 학사학위 논문을 인준함

지도교수 박기주

A handwritten signature in black ink, appearing to read 'Park Ki-ju' (박기주), written in a cursive style.

경희대학교

2025년 12월

경희대학교 2025년도 졸업논문

Performance Comparison of Pre-Trained CNN Models

in CT Image Prediction

- 의료 CT 영상 분류를 위한 사전학습 모델 평가 연구 -



이름: 이 레

학과: 전자정보대학 생체 의공학과

학번: 2021110110

지도 교수: 박기주

Abstract

본 연구는 복부 CT 영상에서 장기 별 손상(장, 출혈, 신장, 간, 비장)을 분류하기 위해 사전학습(Pre-trained)된 CNN 모델인 VGG11, ResNet18, EfficientNet-B1의 성능을 비교·평가하였다. RSNA 2023 Abdominal Trauma Detection 데이터셋의 일부를 사용하였으며, 각 장기별로 이진(건강/손상)분류와 3-class(건강/경도/중도) 분류를 수행하였다. 영상은 HU 변환(WC=50, WW=400) 및 256×256 PNG 정규화를 거쳐 학습에 사용되었고, 백본은 사전 학습 가중치를 유지한 채 Focal BCE/CE 손실함수와 Cosine-decay 학습 스케줄을 적용하였다.

검증 결과 EfficientNet-B1은 F1-score 0.70(± 0.32), 테스트에서는 0.65(± 0.21)로 가장 안정적이고 일반화된 성능을 보였다. 반면 VGG11은 평균 성능이 낮고 변동성이 컸으며, ResNet18은 중간 수준의 결과를 보였다. EfficientNet-B1의 우수한 성능은 MBConv 및 SE 구조, 그리고 SiLU 활성화함수에 의해 미세 영상 특징을 효율적으로 학습한 결과로 해석된다.

따라서, 모델의 깊이·효율적 구조·데이터 균형화 전략이 제한된 의료영상 환경에서 손상 분류 성능 향상에 핵심적임을 확인하였다. 향후 연구에서는 세그멘테이션 기반 크롭 및 오버샘플링을 추가 적용하여 다장기 손상 인식의 임상적 신뢰도를 높이는 것을 목표로 한다.

Table of contents

Abstract	i
List of figures	iii
1. Introduction	1
1.1 연구의 배경 및 필요성	1
1.2 복부 외상의 임상적 중요성	1
1.3 영상 기반 외상 진단의 한계와 인공지능의 필요성	1
1.4 RSNA 2023 Abdominal Trauma Detection Dataset 설명	2
2. Method	2
2.1 Dataset 구성 및 라벨 구조	2
2.2 데이터 전처리 과정	4
2.3 모델구조	4
2.3.1 Baseline 모델 별 특징	4
2.3.2 최종 Base line 모델	5
2.4 학습과정	6
2.4.1 Optimizer, Learning rate, Loss function	6
2.4.2 GPU 환경 및 사용언어, 그리고 학습 세부설정	7
2.5 평가지표	7
3. Results	7
3.1 Baseline 모델 별 성능비교	7
3.2 데이터 증강 수준에 따른 분류 성능 변화 분석	10
4. Discussions	12
5. Conclusions	13
6. Reference	13

List of Figures and Tables

Figure 1	RSNA 공개 데이터셋과 Subset Train 데이터 분포 그래프	3
Figure 2	Raw image 전처리	4
Figure 3	SE block 구조	5
Figure 4	EfficientNet-B1 백본 모델 파이프라인	6
Table 1	baseline VGG11 결과 요약	8
Table 2	baseline ResNet18 결과 요약	9
Table 3	baseline EfficientNet-B1 결과 요약	9
Table 4	advanced augmentation VGG11 결과 요약	10
Table 5	advanced augmentation ResNet18 결과 요약	11
Table 6	advanced augmentation EfficientNet-B1 결과 요약	11

1. Introduction

1.1 연구의 배경 및 필요성

최근 딥러닝 기반 영상 인식 기술이 급속도로 발전하면서 의료영상 분석 분야에서도 인공지능 기술의 활용이 활발히 이루어지고 있다. 특히 합성곱 신경망(Convolutional Neural Network, CNN)은 질병 진단, 장기 분할, 병변 검출 등 다양한 영상 기반 의료 응용 분야에서 우수한 성능을 보이며 임상 보조 도구로서의 가능성을 입증하고 있다.

그러나 의료영상 분야는 개인정보 보호 문제, 데이터 수집의 어려움, 전문 의료진의 고비용 라벨링 작업 등으로 인해 대규모 학습 데이터 확보가 어렵다. 이로 인해 모델 학습 과정에서 과적합(overfitting) 문제가 빈번하게 발생하며, 실제 임상 환경에 적용하기에는 일반화 성능이 부족한 경우가 많다. 따라서 제한된 데이터 환경에서도 안정적인 성능을 유지할 수 있는 모델 구조와 학습 전략을 탐구하는 것이 중요한 연구 과제로 대두되고 있다.

이러한 배경 속에서 본 연구는 사전 학습된 CNN 모델을 활용한 전이 학습 기반 접근법을 통해 소규모 의료영상 데이터에서도 신뢰성 있는 진단 성능을 달성하는 것을 목표로 한다.

1.2 복부 외상의 임상적 중요성

복부 외상은 교통사고, 낙상, 산업재해 등 다양한 원인으로 발생하며, 적절한 시점에 진단이 이루어지지 않을 경우 치명적인 결과로 이어질 수 있다. 특히 장 파열, 장기 출혈, 실질 장기 손상 등은 초기 증상이 뚜렷하지 않은 경우가 많아 영상 기반 진단이 매우 중요하다.

복부 장기는 신체 내부 깊숙한 곳에 위치해 있어 외관상 손상이 드러나지 않는 경우가 흔하며, 이로 인해 신속하고 정확한 영상 판독이 환자의 생존율을 좌우하는 핵심 요소가 된다. 특히 활성 출혈(extravasation)이나 장 천공(bowel injury)은 지연 진단 시 급격한 상태 악화로 이어질 수 있어 조기 발견이 필수적이다.

따라서 복부 CT 영상에서 각 장기의 손상 여부를 신속하고 정확하게 판단할 수 있는 자동화된 분석 시스템은 응급의학 및 외상 진료 분야에서 매우 중요한 의미를 갖는다.

1.3 영상 기반 외상 진단의 한계와 인공지능의 필요성

현재 복부 외상 진단은 주로 영상의학과 전문의의 육안 판독에 의존하고 있다. 하지만 CT 영상은 장기 간 밀도가 유사하고 손상 양상이 미세한 경우가 많아 판독 자체가 고난이도

작업에 해당하며, 판독자의 숙련도에 따라 해석 결과가 달라질 수 있다. 또한 응급 상황에서는 제한된 시간 내에 다량의 영상을 분석해야 하므로 판독 피로도와 휴먼 에러 가능성 역시 문제가 된다.

이러한 환경에서 인공지능 기반 자동 진단 시스템은 의료진의 판단을 보조하는 중요한 역할을 수행할 수 있다. CNN 기반 모델은 영상 내 패턴을 자동으로 학습하여 인간이 인지하기 어려운 미세한 변화까지 감지할 수 있으며, 지속적으로 동일한 기준으로 분석을 수행하기 때문에 진단 일관성을 확보할 수 있다.

특히 최근에는 다양한 사전 학습 모델(VGG, ResNet, EfficientNet 등)이 제안되면서, 모델 구조에 따른 특징 추출 능력과 일반화 성능에 대한 비교 연구의 필요성도 함께 증가하고 있다. 이에 따라 임상 데이터 환경에 가장 적합한 네트워크 구조를 규명하는 연구가 요구된다.

1.4 RSNA 2023 Abdominal Trauma Detection 설명

RSNA 2023 Abdominal Trauma Detection 프로젝트는 응급 상황에서 복부 CT 기반 장기 손상(출혈, 장 손상, 간·비장·신장 손상)을 신속하게 탐지하기 위한 인공지능 모델 개발을 목표로 한 임상 중심 AI 챌린지이다. 본 과제는 다기관 CT 데이터를 기반으로 환자별 장기 손상 여부 및 등급(healthy/low/high)을 예측하는 binary-class, multi-class 분류 문제로 구성되며, 병변의 형태 다양성·저해상도·클래스 불균형 등 실제 임상에서 직면하는 여러 난제를 포함하고 있다. 이러한 특성 때문에 RSNA 프로젝트는 복부 외상 자동 진단 모델의 개발 및 평가를 위한 중요한 벤치마크로 활용되고 있으며, 본 연구에서도 해당 문제 정의를 유지한 상태에서 백본 구조 및 증강 전략의 성능 영향을 분석하였다.

2.Methods

2.1 Dataset 구성 및 라벨 구조

RSNA 2023 Abdominal Trauma Detection Challenge에서 공개된 복부 외상 원본 CT 데이터셋은 총 4,274명의 환자와 6,481개의 CT 시리즈로 구성되어 있으며, 환자 단위로 bowel, extravasation, kidney, liver, spleen에 대한 손상 여부 및 중증도 라벨이 제공된다. 이때 bowel과 extravasation은 정상(healthy)과 손상(injury)의 2-class 분류 문제로, kidney, liver, spleen은 정상(healthy), 저등급 손상(low), 고등급 손상(high)의 3-class 분류 문제로 정의된다.

원본 데이터셋은 대부분이 정상(healthy) 환자로 구성되어 있어 클래스 불균형이 매우 심한 특징을 가진다. 특히 extravasation과 고등급 장기 손상(high grade injury)의 비율은 극히 낮아, 원본 데이터 전체를 그대로 학습에 사용할 경우 모델이 정상 클래스에 편향되고 병변 검출 민감도가 저하될 가능성이 크다. Figure 1의 왼쪽 그래프는 원본 데이터셋에서 각 장기별 클래스 분포를 나타낸 것으로, 대부분의 클래스에서 healthy 비율이 90% 이상을 차지하고 있으며, injury, low, high 클래스는 극소수임을 확인할 수 있다.




Figure 1 RSNA 공개 데이터셋과 Subset Train 데이터 분포 그래프

이러한 심한 불균형 문제를 완화하기 위해, 본 연구에서는 원본 데이터셋 중 병변이 상대적으로 많이 포함된 환자를 중심으로 별도의 subset을 구성하였다. Subset 데이터는 Kaggle을 통해 공개된 복부 슬라이스 crop 데이터셋을 참고하여 확보하였으며, 최종적으로 207명의 환자와 약 10,559장의 슬라이스를 포함하는 학습용 데이터셋을 구축하였다. 해당 subset은 원본 데이터셋의 장기 별 라벨 구조를 유지하면서도, 병변 클래스의 비율이 일정 수준 확보되도록 구성하였다.

Figure 1의 오른쪽 그래프는 subset train 데이터의 클래스 분포를 나타낸 것으로, 원본 데이터에 비해 injury 및 low/high 클래스의 비율이 눈에 띄게 증가하였음을 확인할 수 있다. 예를 들어 bowel과 extravasation의 경우 injury 비율이 약 20% 이상으로 증가하였으며, kidney, liver, spleen 또한 low 및 high 클래스가 의미 있는 비율로 포함되어 있다. 이는 병변 샘플 수를 의도적으로 확보하여 모델이 소수 클래스의 구조적 특징을 보다 명확히 학습할 수 있도록 한 설계이다.

Subset 데이터는 train: validation: test를 6:2:2 비율의 stratified split으로 구성하여 장기별 클래스 분포가 모든 split에서 유사하게 유지되도록 하였다. 학습 데이터에서는 병변 비율을 증가시켜 클래스 불균형을 완화하고, 병변 검출 성능 향상을 유도하였다. 또한 데이터 구성 단계에서의 병변 비율 조정과 더불어, 학습 과정에서는 Focal Loss 및 샘플러, 클래스 가중치 등의 기법을 적용하여 불균형 문제를 추가적으로 보완하였고, 데이터 증강을 통해 소수 클래스에 대한 학습 기회를 확대하였다.

2.2 데이터 전처리 과정

본 연구에서는 CT 원본 영상(DICOM)을 딥러닝 모델 학습에 적합한 형태로 변환하기 위해 아래와 같은 전처리 과정을 수행하였다.

먼저 DICOM 형식의 CT 영상은 Hounsfield Unit (HU) 단위로 변환한 후, HU 값의 중간 값을 중심으로 일정 범위 내의 조직 정보(연부조직)만을 강조하기 위해 window center(WC)=50, window width(WW)=400의 윈도우를 적용하였다. 이를 통해 간, 비장, 신장과 같은 복부 장기의 구조가 보다 명확하게 표현되도록 하였다. 이후 영상의 해상도를 256×256으로 resize하여 모델 입력 크기를 통일하였다. 다음으로 모든 CT 이미지에 대해 밝기 값 정규화를 수행하고, PNG 형식으로 변환하여 저장하였다. 이러한 과정을 통해 영상 간 명암 차이를 줄이고, 학습 과정에서 안정적인 입력 데이터 분포를 유지하도록 하였다.

Figure 2는 Raw CT 영상에 전처리 과정을 적용한 예시를 보여주며, 전처리 이후 장기 윤곽 및 조직 대비가 뚜렷해졌음을 확인할 수 있다.




Figure 2 Raw image 전처리

2.3 모델구조

2.3.1 Baseline 모델 별 특징

VGG는 3×3 convolution과 max pooling을 반복적으로 쌓은 단순한 CNN 구조로, 직관적이며 해석이 용이하지만, 파라미터 수가 많고 Skip connection 없으며 연산량이 상대적으로 크다는 특징을 가진다.

ResNet은 Skip connection을 이용하여 깊은 네트워크에서도 학습이 안정적으로 이루어지도록 설계된 모델로, Residual Connection(잔차연결) 식 (1)을 통해 입력 feature를 그대로 보존하면서, 네트워크가 학습한 보정 값을 더하여 최종 출력을 생성한다. 이를 통해 깊은 네트워크에서도 gradient 소실 없이 안정적인 학습이 가능하고 또한 구조 대비 우수한 일반화 성능을 가진다는 특징이 있다.

$$y = F(x) + x \quad (1)$$

EfficientNet은 모델의 깊이, 너비, 입력 해상도를 동시에 조절하는 compound scaling 기법을 적용한 CNN 구조이다. 채널을 확장한 뒤 공간 정보를 처리하고 다시 축소함으로써 연산 효율과 표현력을 동시에 향상시키는 역할을 하는 MBConv block을 특징적으로 가지며, 이로 인해 높은 파라미터 효율과 작은 모델 크기 대비 빠른 학습 속도를 보이고 경량 모델 중에서 우수한 성능을 달성한다. Figure3에 나와있는 MBConv block 내부에 포함된 SE Block은 채널 별 중요도를 학습하여 의미 있는 특징은 강화하고, 불필요한 특징은 억제하는 attention 모듈로 작동한다.




Figure 3 SE block 구조

2.3.2 최종 Base line 모델

본 연구에서는 RSNA 데이터셋의 일부만을 사용하므로, 저해상도 및 소규모 데이터 환경에서도 안정적인 일반화 성능을 확보할 수 있는 모델이 필요하였다. 이에 따라 소형에서 중형 규모의 구조를 갖는 VGG11, ResNet18, EfficientNet-B1을 최종 비교 모델로 선정하였다. 또한 시간적 제약과 연산 자원, 학습 효율을 고려할 때 상위 버전 모델들은 파라미터 수와 연산량이 급격히 증가하여 반복 실험 및 교차 검증에 부담이 되기 때문에, 본 연구에서는 비교적 경량이면서도 CNN 구조의 발전 단계를 대표할 수 있는 모델들을 선택하여 성능을 비교하였다.

baseline 실험은 Figure 4의 파이프라인에서 백본(Backbone) 블록만을 서로 교체하는 방식으로 구성하였다. 즉, 동일한 입력 전처리, 동일한 classification head(이진/다중 클래스 neck은 silu함수 사용), 동일한 loss 계산 및 scheduler 구조를 유지한 상태에서, 백본을 VGG11 → ResNet18 → EfficientNet-B1로 변경하여 모델 구조 자체가 갖는 표현력 차이를 평가하였다. baseline에서는 좌우 반전, 상하 반전, Random Erasing 등 최소 수준의 데이터 증강만을 적용하여 모델 구조의 순수한 성능 차이를 확인하고자 하였다.




Figure 4 EfficientNet-B1 백본 모델 파이프라인

이후 강화된 ablation 실험에서는 동일한 파이프라인을 유지한 채, 추가적인 기하학적·광학적 변형을 적용하여 데이터 증강 강도에 따른 모델의 반응 변화를 단계적으로 분석하였다. 이러한 설계는 백본 구조적 특성에 따라 성능이 어떻게 달라지는지, 그리고 증강 전략이 소규모 데이터에서 모델 일반화에 어떠한 영향을 미치는 지를 명확히 평가하기 위한 것이다.

2.4 학습과정

2.4.1 Optimizer, Learning rate, Loss function

모델 학습에는 Adam optimizer를 사용하였으며, 배치 크기는 32로 설정하고 입력 영상은 256×256 해상도로 통일하였다. 초기 학습률(learning rate)은 1×10^{-4} 로 설정하였고, 일정 에폭 동안 학습이 안정화되도록 한 뒤 1×10^{-3} 까지 점진적으로 증가시키는 warm-up 전략을 적용하였다. Warm-up 이후에는 cosine decay 스케줄러를 사용하여 학습 후반부에서 학습률이 부드럽게 감소되도록 하여 과적합을 방지하였다.

손실 함수는 예측 대상의 특성에 따라 다르게 적용하였다. 이진 분류(bowel, extravasation)의 경우 Focal-BCE를 사용하였으며, 장기 손상 등 다중 클래스 분류 과제(kidney, liver, spleen)에는 Focal-Cross Entropy를 적용하였다. Focal loss는 클래스 불균형 상황에서 소수 클래스의 학습 기여도를 증가시키는 장점이 있어 본 연구의 데이터 특성에 적합하다고 판단하였다.

2.4.2 GPU 환경 및 사용언어, 그리고 학습 세부설정

모델 학습은 NVIDIA GeForce RTX 5090 GPU가 장착된 환경에서 수행하였다. 구현은 Python 3.11.14 기반으로 진행하였으며, 딥러닝 프레임워크로는 PyTorch를 사용하였다.

학습은 총 20 epochs 동안 진행되었으며, 입력 영상 크기는 256×256 으로 통일하였다. Batch size는 32로 설정하여 GPU 메모리 효율성과 수렴 안정성을 균형 있게 확보하였다. 모델의 일반화 성능을 향상시키기 위해 랜덤 회전과 중심 기반 변형을 포함한 기본적인 데이터 augmentation 기법을 적용하였다.

feature extractor(backbone)는 사전학습 가중치를 유지한 채 동결(freeze)하고, 각 장기별 예측을 위한 분류 head만 학습하도록 설계하여 파라미터 효율성과 학습 안정성을 확보하였다. 또한 Early stopping은 검증 손실이 5×10^{-4} 이상 개선되지 않는 상태가 8회 연속 지속될 경우 학습을 중단하도록 patience=8 기준으로 적용하였다.

2.5 평가지표

본 연구에서는 분류 성능을 다각도로 평가하기 위해 Precision, Recall, F1-score, Accuracy를 사용하였다. Accuracy는 전체적인 예측 정확도를 확인하기 위한 기본 지표이며, Precision과 Recall은 클래스 간 불균형이 존재하는 의료 영상 분류에서 오탐지와 미탐지의 위험성을 정량적으로 평가하는 데 필요하다. 특히 F1-score는 Precision과 Recall의 조화평균으로, 두 지표 간 균형을 평가할 수 있어 불균형 데이터 환경에서 더 신뢰도 높은 성능 지표로 간주된다. 이러한 이유로 본 연구에서는 F1-score를 주요 평가지표로 활용하여 모델의 임상적 활용 가능성을 판단하였다.

3.Results

3.1 Baseline 모델 별 성능비교

3.1 에서는 기본적인 수준의 데이터 증강을 적용한 baseline 조건에서 VGG11(Table 1), ResNet18(Table 2), EfficientNet-B1(Table 3)의 성능을 비교하였다. 각 모델은 동일한 학습 설정과 데이터 구성에서 평가되었으며, 이를 통해 모델 구조의 차이가 분류 성능에 미치는 영향을 직접적으로 확인하고자 하였다. 아래 표는 세 모델의 클래스별 Precision, Recall, F1-score, Accuracy를 제시하며, 이를 기반으로 baseline 환경에서의 상대적 성능 특성을 분석하였다.

		PRECISION	RECALL	F1	ACC
VALIDATION	Bowel	0.2857	0.6667	0.4000	0.6087
	Extravasation	0.8696	0.5000	0.6349	0.5000
	Kidney	0.2868	0.3162	0.3008	0.8043
	Liver	0.3250	0.4150	0.3626	0.6957
	spleen	0.4805	0.5146	0.4725	0.5870
TEST	Bowel	0.3684	0.7000	0.4828	0.6591
	Extravasation	0.8750	0.6000	0.7119	0.6136
	Kidney	0.3008	0.3246	0.3122	0.8409
	Liver	0.2791	0.3243	0.3000	0.8182
	spleen	0.4056	0.4464	0.4094	0.5682

Table 1 baseline VGG11 결과 요약

VGG11(Table 1)은 전체적으로 안정적인 정확도를 보였으나, 클래스별 F1-score는 전반적으로 낮게 나타났다. Validation 단계에서 extravasation은 비교적 높은 Precision(0.8696)과 F1(0.6349)을 보였으나, 나머지 클래스에서는 Precision과 Recall의 불균형이 컸고 종합적인 F1-score는 0.30~0.47 수준에 머물렀다. Test에서도 전반적으로 비슷한 경향을 보이며, 특히 kidney와 liver 클래스에서 F1-score가 0.30 내외로 낮았다. 즉, VGG11은 단순 구조로 인해 특정 클래스(extravasation)는 잘 식별하지만, 복잡한 장기 손상 분류에서는 일반화 성능이 제한적으로 나타났다.

		PRECISION	RECALL	F1	ACC
VALIDATION	Bowel	0.3125	0.5556	0.4000	0.6739
	Extravasation	0.8684	0.8250	0.8462	0.7391
	Kidney	0.2857	0.3077	0.2963	0.7826
	Liver	0.3110	0.3366	0.3193	0.5652
	spleen	0.3208	0.1271	0.1685	0.2174
TEST	Bowel	0.5000	0.7000	0.5833	0.7727
	Extravasation	0.8182	0.7714	0.7941	0.6818
	Kidney	0.4038	0.3825	0.3871	0.8409
	Liver	0.2877	0.2725	0.2525	0.5000
	spleen	0.3861	0.3848	0.3419	0.4318

Table 2 baseline ResNet18 결과 요약

ResNet18(Table 2)은 VGG11 대비 전반적으로 개선된 성능을 보였다. Validation 단계에서 extravasation F1-score는 0.8462로 세 모델 중 가장 높은 값을 기록하였으며, bowel F1-

score 또한 VGG11 대비 개선되었다. 그러나 spleen 클래스에서 Recall이 크게 낮아(F1-score 0.1685) 클래스별 편차가 존재했다. Test 단계에서는 대부분의 클래스에서 F1-score가 향상되어 bowel(0.5833), extravasation(0.7941) 등 주요 병변 분류에서 강점을 보였으나, liver와 spleen은 여전히 낮은 값을 기록했다. 즉, ResNet18은 상대적으로 균형 잡힌 특징 추출 능력을 보이거나 특정 소수 클래스에서 불안정성이 존재한다.

		PRECISION	RECALL	F1	ACC
VALIDATION	Bowel	0.4167	0.5556	0.4762	0.7609
	Extravasation	0.9677	0.7500	0.8451	0.7609
	Kidney	0.4028	0.5214	0.4435	0.8043
	Liver	0.5357	0.7244	0.5681	0.6304
	spleen	0.7626	0.5542	0.5818	0.7174
TEST	Bowel	0.4000	0.4000	0.4000	0.7273
	Extravasation	0.9000	0.7714	0.8308	0.7500
	Kidney	0.2937	0.3246	0.3083	0.8409
	Liver	0.2778	0.2252	0.2488	0.5682
	spleen	0.4056	0.4881	0.4335	0.6591

Table 3 baseline EfficientNet-B1 결과 요약

EfficientNet-B1(Table 3)은 validation 단계에서 전반적으로 가장 우수한 F1-score를 기록하였다. 특히 extravasation(0.8451), spleen(0.5818), liver(0.5681)에서 ResNet18보다도 향상된 성능을 보였으며, kidney에서도 비교적 높은 Recall과 F1-score를 유지하였다. Test 단계에서도 안정적인 성능 경향을 유지하며, 주요 클래스에서 VGG11 대비 일관된 우위를 나타냈다. 다만 bowel test F1-score는 0.4000으로 validation 대비 감소하는 경향이 있었다.

Table 1-3의 baseline 결과를 종합하면, VGG11(Table 1)은 단순한 네트워크 구조의 한계로 인해 전반적인 분류 성능이 가장 낮았으며, 특히 kidney, liver, spleen과 같은 다중 클래스 장기 손상 분류에서 F1-score가 크게 저하되는 양상을 보였다. ResNet18(Table 2)은 이러한 VGG11 대비 뚜렷한 성능 향상을 보이며 bowel과 extravasation 분류에서 강점을 나타냈으나, 여전히 spleen·liver 등 소수 클래스에서는 불안정성이 남아 있었다. 반면, EfficientNet-B1(Table 3)은 validation 기준으로 대부분의 클래스에서 가장 높은 F1-score를 기록하였으며, 특히 spleen, liver, extravasation과 같이 복잡한 패턴을 갖는 클래스에서도 안정적인 성능을 보여 세 모델 중 가장 우수한 결과를 보였다. 따라서 기본 augmentation 조건에서 EfficientNet-B1이 가장 뛰어난 분류 성능을 가진 모델로 평가되

었으며, VGG11은 가장 낮은 성능을 보였고, ResNet18은 VGG11 대비 개선된 성능을 보이지만 EfficientNet-B1보다는 한 단계 낮은 성능을 나타냈다.

3.2 데이터 증강 수준에 따른 분류 성능 변화 분석

앞선 3.1절에서는 좌우 반전, 상하 반전, Random Erasing 등 기본적인 수준의 증강만 적용한 baseline 조건에서 세 모델을 비교하였다. 본 절에서는 동일한 모델 구조를 유지한 채, baseline 대비 추가적인 기하학적(작은 회전·이동·스케일 변화, RandomResizedCrop), 광학적 변형(ColorJitter), Gaussian Blur 등을 포함한 강화된 데이터 증강(advanced augmentation)을 적용하여 성능 변화를 분석하였다.

		PRECISION	RECALL	F1	ACC
VALIDATION	Bowel	0.5000	0.1111	0.1818	0.8043
	Extravasation	0.8696	1.0000	0.9302	0.8696
	Kidney	0.2868	0.3162	0.3008	0.8043
	Liver	0.3195	0.4150	0.3537	0.6957
	spleen	0.4632	0.4375	0.4478	0.6739
TEST	Bowel	0.3333	0.1000	0.1538	0.7500
	Extravasation	0.8095	0.9714	0.8831	0.7955
	Kidney	0.2846	0.3070	0.2954	0.7955
	Liver	0.2750	0.2973	0.2857	0.7500
	spleen	0.4103	0.4940	0.4299	0.5909

Table 4 advanced augmentation VGG11 결과 요약

VGG11(Table 4)은 baseline 대비 전체적인 성능 변화 폭이 크지 않았으나, 일부 클래스에서 Recall이 증가하면서 F1-score가 소폭 개선되었다. 특히 validation 단계에서 extravasation은 Recall이 1.0까지 상승하며 높은 F1-score(0.9302)를 기록했으나, bowel과 kidney 클래스는 여전히 낮은 값에 머물렀다. Test 단계에서도 extravasation 성능은 유지되었지만, 다른 클래스의 F1-score가 제한적인 수준을 보여, 추가 증강이 VGG11의 전반적인 구조적 한계를 크게 개선하지는 못한 것으로 해석된다.

		PRECISION	RECALL	F1	ACC
VALIDATION	Bowel	0.6250	0.5556	0.5882	0.8478
	Extravasation	0.9375	0.7500	0.8333	0.7391
	Kidney	0.3849	0.4359	0.4080	0.8478
	Liver	0.5726	0.3856	0.4224	0.6304

	spleen	0.4060	0.3917	0.3879	0.6739
TEST	Bowel	0.4667	0.7000	0.5600	0.7500
	Extravasation	0.9200	0.6571	0.7667	0.6818
	Kidney	0.6349	0.4000	0.4278	0.8864
	Liver	0.2745	0.2523	0.2629	0.6364
	spleen	0.2323	0.2396	0.2359	0.5227

Table 5 advanced augmentation ResNet18 결과 요약

ResNet18(Table 5)은 VGG11보다 증강 효과가 더 명확하게 나타났다. Validation에서 extravasation, kidney, liver 등 대부분의 클래스에서 Precision과 Recall이 균형적으로 증가하며 F1-score가 전반적으로 향상되었다. Test 단계에서도 bowel, kidney 등 주요 클래스에서 baseline 대비 성능 개선이 확인되며, 비교적 안정적인 결과를 유지하였다. 다만 spleen 클래스는 Recall이 낮아 여전히 불안정성을 보였으나, 전반적으로 ResNet18은 증강 강도 증가에 긍정적으로 반응하는 경향을 보였다.

		PRECISION	RECALL	F1	ACC
VALIDATION	Bowel	0.5000	0.4444	0.4706	0.8043
	Extravasation	0.9474	0.9000	0.9231	0.8696
	Kidney	0.3512	0.4103	0.3750	0.7826
	Liver	0.5458	0.6797	0.5176	0.6522
	spleen	0.7439	0.4625	0.5025	0.7174
TEST	Bowel	0.5000	0.5000	0.5000	0.7727
	Extravasation	0.8182	0.7714	0.7941	0.6818
	Kidney	0.2868	0.3246	0.3045	0.8409
	Liver	0.2688	0.2252	0.2451	0.5682
	spleen	0.4250	0.4182	0.4082	0.7500

Table 6 advanced augmentation EfficientNet-B1 결과 요약

EfficientNet-B1(Table 6)은 baseline 대비 대부분의 클래스에서 Precision과 Recall이 향상되었으며, 특히 validation 단계에서 extravasation(0.9231), liver(0.5176), spleen(0.5025) 등에서 F1-score가 높아졌다. Test 단계에서도 bowel을 제외한 대부분의 클래스에서 안정적 성능을 유지하였다. 전반적으로 EfficientNet-B1은 추가 증강의 효과를 가장 안정적으로 흡수하며 세 모델 중 가장 높은 성능 일관성을 보인 모델로 평가된다.

Table 4-6을 종합하면, 추가 증강 적용 시 VGG11은 구조적 한계로 인해 성능 향상이 제한적이었던 반면, ResNet18은 여러 클래스에서 개선이 나타났고 EfficientNet-B1은 가장

안정적이고 높은 성능 향상을 보였다. 즉, advanced augmentation 환경에서도 EfficientNet-B1이 가장 우수한 모델로 유지되며, VGG11은 증강만으로 성능 개선이 어렵다는 점이 확인되었다.

4. Discussions

본 연구에서는 RSNA Abdominal Trauma Detection 데이터셋의 일부만을 활용하여 소규모·저해상도 환경에서 세 가지 CNN 백본(VGG11, ResNet18, EfficientNet-B1)의 분류 성능을 비교하였다. Baseline 실험 결과 EfficientNet-B1은 MBConv 기반의 inverted bottleneck 구조, 채널 중요도를 동적으로 조절하는 SE(Squeeze-and-Excitation) 모듈, 깊이·너비·해상도를 균형적으로 확장하는 compound scaling 전략의 결합을 통해 가장 높은 F1-score와 안정적인 학습 곡선을 보였다. 이러한 구조적 특징은 특히 저해상도 슬라이스에서도 의미 있는 국소 특징을 효과적으로 증폭·보존할 수 있어, 제한된 데이터 환경에서 feature 학습의 안정성과 데이터 적응력이 높게 나타났고, 결과적으로 다른 모델에 비해 우수한 일반화 성능을 보여준 것으로 판단된다. 반면 VGG11은 단순한 stack 구조로 인해 클래스 간 성능 편차가 크게 나타났으며, ResNet18은 skip connection을 바탕으로 비교적 균형 잡힌 성능을 보였으나 소수 클래스에서의 성능 저하가 확인되어 구조적 한계가 일부 드러났다.

추가적인 기하학적·광학적 증강을 적용한 ablation 실험에서도 모델 간 반응은 일관되지 않았다. EfficientNet-B1은 증강 강도 증가에도 SE 모듈 기반의 채널 attention과 MBConv의 효율적 feature extraction 덕분에 성능 안정성을 유지하며 대부분의 클래스에서 향상된 F1-score를 보였던 반면, VGG11은 구조적 제약으로 인해 개선 폭이 제한적이었다. ResNet18은 증강에 긍정적으로 반응했으나 EfficientNet-B1 수준의 일관된 향상은 확보하지 못하였다. 이러한 결과는 모델 구조적 특성이 소규모 데이터 환경에서의 일반화 성능을 결정하는 핵심 요소이며, 데이터 증강 전략이 각 백본의 내부 연산 방식에 따라 상이한 효과를 나타낸다는 점을 시사한다.

세 모델 모두에서 공통적으로 다중 클래스(head) 분류 성능이 낮게 나타난 점도 중요한 관찰이다. 이는 클래스 간 샘플 불균형, 병변 경계의 모호성, slice-level 입력 구조 제한 등 다양한 요인이 복합적으로 작용한 것으로 보인다. 또한 데이터 규모가 제한적이기 때문에 증강 강도 증가가 모든 클래스에서 일관된 성능 향상으로 이어지지 않는 경향도 확인되었다. 이러한 한계를 보완하기 위해 본 연구에서는 장기 기반 3D ROI 추출 및 organ-specific classification이 가능한 파이프라인을 추가적으로 도입하거나 oversampling, class-balanced loss, patient-level aggregation, 3D 기반 모델링 등의 접근도 향후 중요

한 연구 방향으로 고려된다.

5. Conclusions

본 연구에서는 소규모·저해상도 외상 CT 데이터에서 세 가지 CNN 백본을 비교하고, 증강 강도 변화가 모델 성능에 미치는 영향을 평가하였다. EfficientNet-B1은 baseline과 강화 증강 환경 모두에서 가장 높은 성능과 일관성을 보였으며, 복잡한 병변 분류에서도 안정적인 Precision-Recall 균형을 유지하였다. 반면 VGG11은 구조적 단순성으로 인해 성능이 제한적이었고, ResNet18은 중간 수준의 성능과 부분적인 개선을 보였다.

다중 클래스 분류의 전반적인 성능 저하와 데이터 불균형, slice-level 구조의 제약은 본 연구의 주요 한계로 확인되었다. 향후에는 ROI 기반 학습, 불균형 보정 기법, 3D-patient-level 모델 확장 등을 통해 이러한 한계를 개선할 필요가 있다.

종합하면 본 연구는 제한된 의료 영상 환경에서 효과적인 백본 선택과 증강 전략 수립에 참고할 수 있는 근거를 제공하며, 향후 모델의 임상 적용 가능성 향상에 기여할 수 있을 것으로 판단된다.

6. References

- [1] Simonyan, K. & Zisserman, A. (2014). Very Deep Convolutional Networks for Large-Scale Image Recognition. arXiv:1409.1556.
- [2] He, K., Zhang, X., Ren, S., & Sun, J. (2015). Deep Residual Learning for Image Recognition. arXiv:1512.03385.
- [3] Tan, M. & Le, Q. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. arXiv:1905.11946.